PROGRAMME DE FORMATION CONCEPTEUR DÉVELOPPEUR D'APPLICATIONS OU CERTIFICATION PROFESSIONNELLE DÉVELOPPEUR EN INTELLIGENCE ARTIFICIELLE ET DATA SCIENCE RNCP36581

Bloc E6.1 – Créer un modèle de données d'une solution I.A en utilisant des méthodes de Data science

Annexe du coach de la MSPR « Développement et déploiement d'une application dans le respect du cahier des charges Client // Création d'un backend métier permettant le nettoyage et la visualisation des données »

Contexte business critique

La startup HealthAI Coach représente un cas d'usage réel avec 50 000 utilisateurs générant quotidiennement 200k entrées nutritionnelles et 150k sessions d'exercices. Ce volume justifie les préoccupations de performance et qualité des données.

Points d'évaluation prioritaires

Modélisation des données : Vérifier la gestion des données temporelles (historique progressions utilisateurs), la normalisation sans sur-normalisation, et l'optimisation pour les requêtes analytics. Les étudiants sous-estiment souvent les index composés nécessaires.

Qualité du pipeline ETL : Examiner la gestion des doublons inter-sources, la validation métier des données (cohérence BMI/poids/taille), et la reprise sur erreur. Point critique : transformation des formats hétérogènes Kaggle vers schéma unifié.

Interface d'administration : Évaluer l'UX pour utilisateurs non-techniques, la pagination sur gros volumes, et les filtres métier pertinents. Les équipes techniques négligent souvent l'ergonomie.

Indicateurs de difficulté à surveiller

- Blocages sur jointures complexes entre datasets
- Performances dégradées sur agrégations (millions de lignes)
- Interface admin non responsive ou inadaptée aux volumes réels

Questions de validation technique

1. Comment gérez-vous les utilisateurs qui changent d'objectif (perte → gain muscle) ?
2. Quelle stratégie pour les données nutritionnelles manquantes/incohérentes ?
3. Comment l'interface se comporte avec 10 000 utilisateurs affichés ?

Critères de différenciation

Niveau "Acceptable" représente le minimum viable :

- **Pipeline fonctionnel** : Les données entrent, sont transformées et sortent. Les scripts s'exécutent sans crash, mais probablement avec des cas d'usage limités (ex: seulement des fichiers bien formatés, pas de gestion des erreurs réseau).
- **Interface basique** : Dashboard qui affiche des graphiques, filtres qui marchent sur les données de test, navigation fonctionnelle. Typiquement : design Bootstrap par défaut, pas d'optimisation mobile.
- **Données nettoyées** : Suppression des doublons évidents, valeurs nulles traitées, formats standardisés. Mais approche probablement naïve (ex: supprime tous les poids > 200kg sans considérer les athlètes de force).

Niveau "Excellent" montre une approche professionnelle :

- **Gestion des cas limites** : Que fait le système si un utilisateur pèse 300kg (haltérophile) ? Si quelqu'un saisit "j'aime pas les légumes" dans le champ allergies ? Si l'API nutrition renvoie des données incohérentes ? Ces équipes anticipent les edge cases.
- **Monitoring des données** : Alertes automatiques si le taux de nouvelles entrées chute, si la distribution des poids utilisateurs devient anormale, si les temps de traitement augmentent. Pas juste des logs, mais de la surveillance proactive.
- **UX pensée pour la production :** Interface qui reste fluide avec 10 000 utilisateurs affichés, pagination intelligente, états de chargement, messages d'erreur informatifs pour les non-techniques. Design testé sur mobile.